# Архиватор

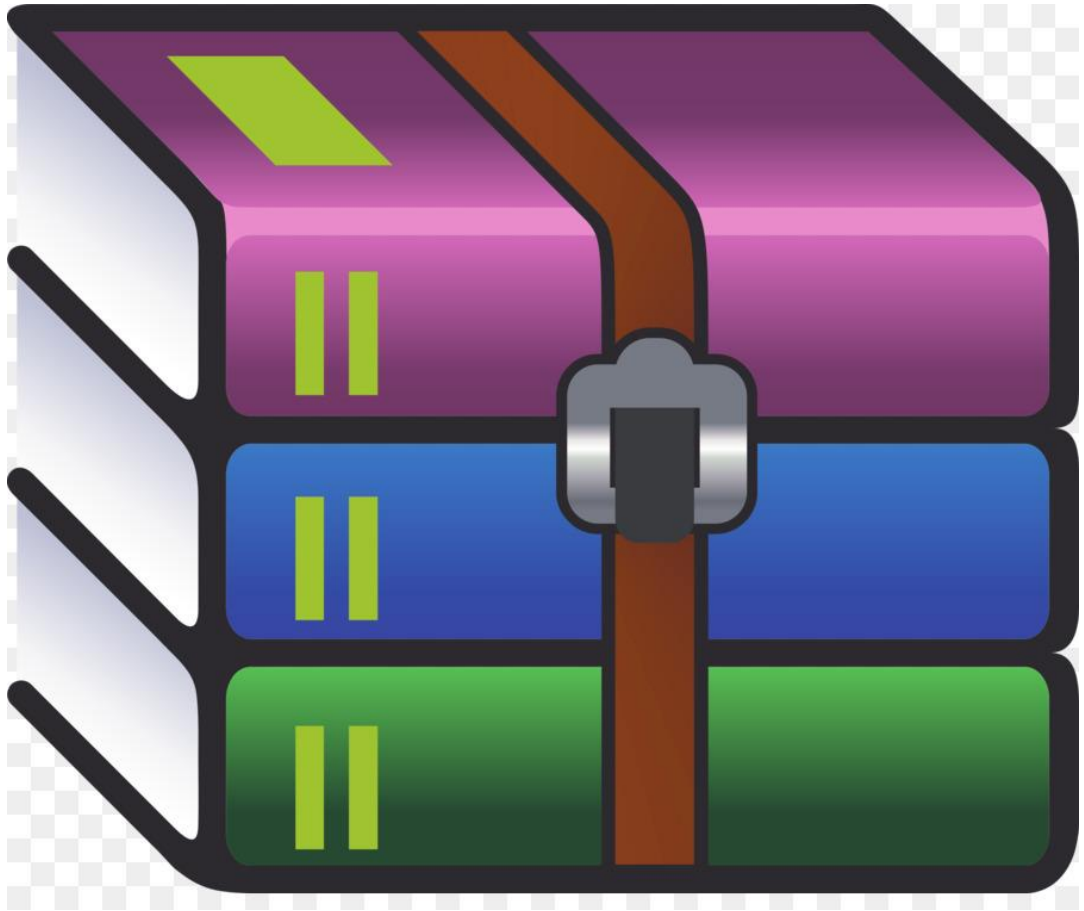

**Задание**

Реализовать программу, кодирующая и сжимающая файлы по алгоритму Хаффмана

Реализовать программу для декодирования файлов

git clone https://github.com/SergeyBalabaev/Archiver

# Основы теории информации

Информация (Information) — содержание сообщения или сигнала; сведения, рассматриваемые в процессе их передачи или восприятия, позволяющие расширить знания об интересующем объекте

Информация – первоначально — сведения, передаваемые одними людьми другим людям устным, письменным или каким-нибудь другим способом

Информация - как коммуникацию, связь, в процессе которой устраняется неопределенность. (К. Шеннон)

# Мера информации

Пусть X – источник дискретных сообщений. Число различных состояний источника – N.
Переходы из одного состояния в другое не зависят от предыдущих состояний, а вероятности перехода в эти состояния $p_j = P\{X = x_j\}$

Тогда за меру количества информации примем следующую величину:

$$H(X) = -\sum_{k=1}^{N} p_k \log(p_k)$$

Эта величина называется **энтропией**

# Энтропия

**Свойства энтропии**

1) Энтропия неотрицательна
2) Максимально возможное значение энтропии равно log(N)
3) Энтропия нескольких независимых файлов равна сумме энтропий каждого из них

**Битовые затраты** – среднее число бит приходящееся на один символ сообщения

$$R=\sum_{k=1}^{N} p_k R_k$$

$R_k$ - число бит в коде символа $x_k$

# Пример

Задача:

Пусть пришло следующее сообщение: «мамамылараму»

Рассчитаем энтропию сообщения и битовые затраты. Будем считать, что один символ кодируется 1 байтом.

1) Рассчитаем вероятности появления символов

мамамылараму

| **Символ** | **м** | **а** | **ы** | **л** | **р** | **у** | **Σ** |
|---|---|---|---|---|---|---|---|
| Количество | 4 | 4 | 1 | 1 | 1 | 1 | **12** |
| Вероятность | 1/3 | 1/3 | 1/12 | 1/12 | 1/12 | 1/12 | **1** |

# Пример

2) Рассчитаем энтропию и битовые затраты

$$H(X) = -\sum_{k=1}^{N} p_k \log(p_k)$$

$$H(X) = -\sum_{k=1}^{6} p_k \log(p_k) = -\left(\frac{1}{3}\log\frac{1}{3} + \frac{1}{3}\log\frac{1}{3} + \frac{1}{12}\log\frac{1}{12} + \frac{1}{12}\log\frac{1}{12} + \frac{1}{12}\log\frac{1}{12} + \frac{1}{12}\log\frac{1}{12}\right) \sim \mathbf{2,25}$$

$$R = \sum_{k=1}^{N} p_k R_k$$

$$H(X) = \sum_{k=1}^{6} p_k R_k = \left(\frac{1}{3} * 8 + \frac{1}{3} * 8 + \frac{1}{12} * 8 + \frac{1}{12} * 8 + \frac{1}{12} * 8 + \frac{1}{12} * 8\right) = \mathbf{8}$$

# Идея сжатия

Давайте заменим стандартный равномерный ASCII код на неравномерный так, чтобы часто встречающимся символам соответствовали более короткие кодовые последовательности. Если средние битовые затраты будут меньше, чем 8 бит, то сжатие удалось!

# Алгоритм Хаффмана

На вход алгоритма подается таблица символов

1. Построение дерева Хаффмана
    1. Упорядочиваем таблицу символов в порядке убывания вероятностей
    2. Два последних символа, имеющих наименьшие вероятности появления объединяются в новый символ
    3. Если есть еще символы, то возвращаемся на 1.1
2. Построение битового кода

    Для каждого узла дерева строим по два ребра, приписываем одному из них 1, другому 0

# Алгоритм Хаффмана - пример

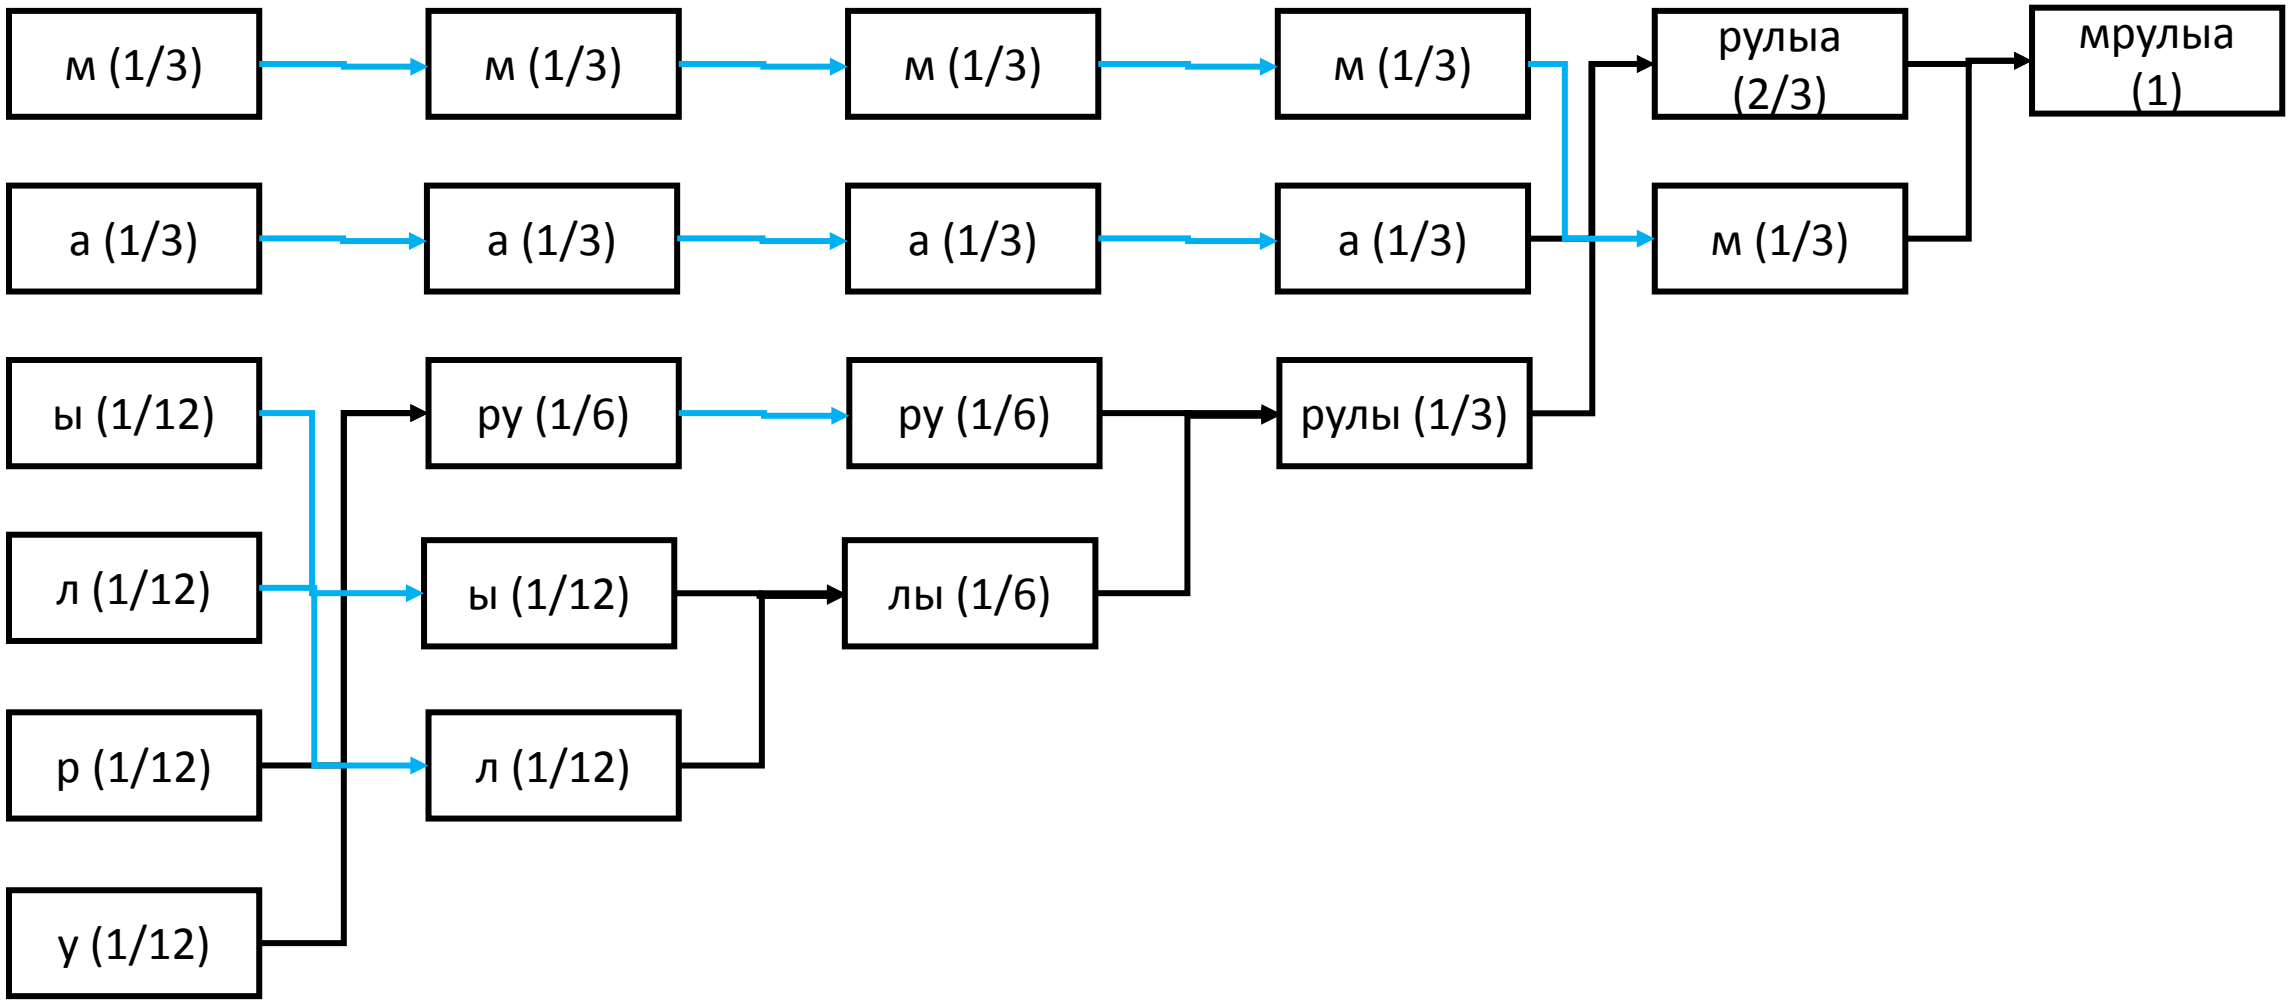

# Алгоритм Хаффмана

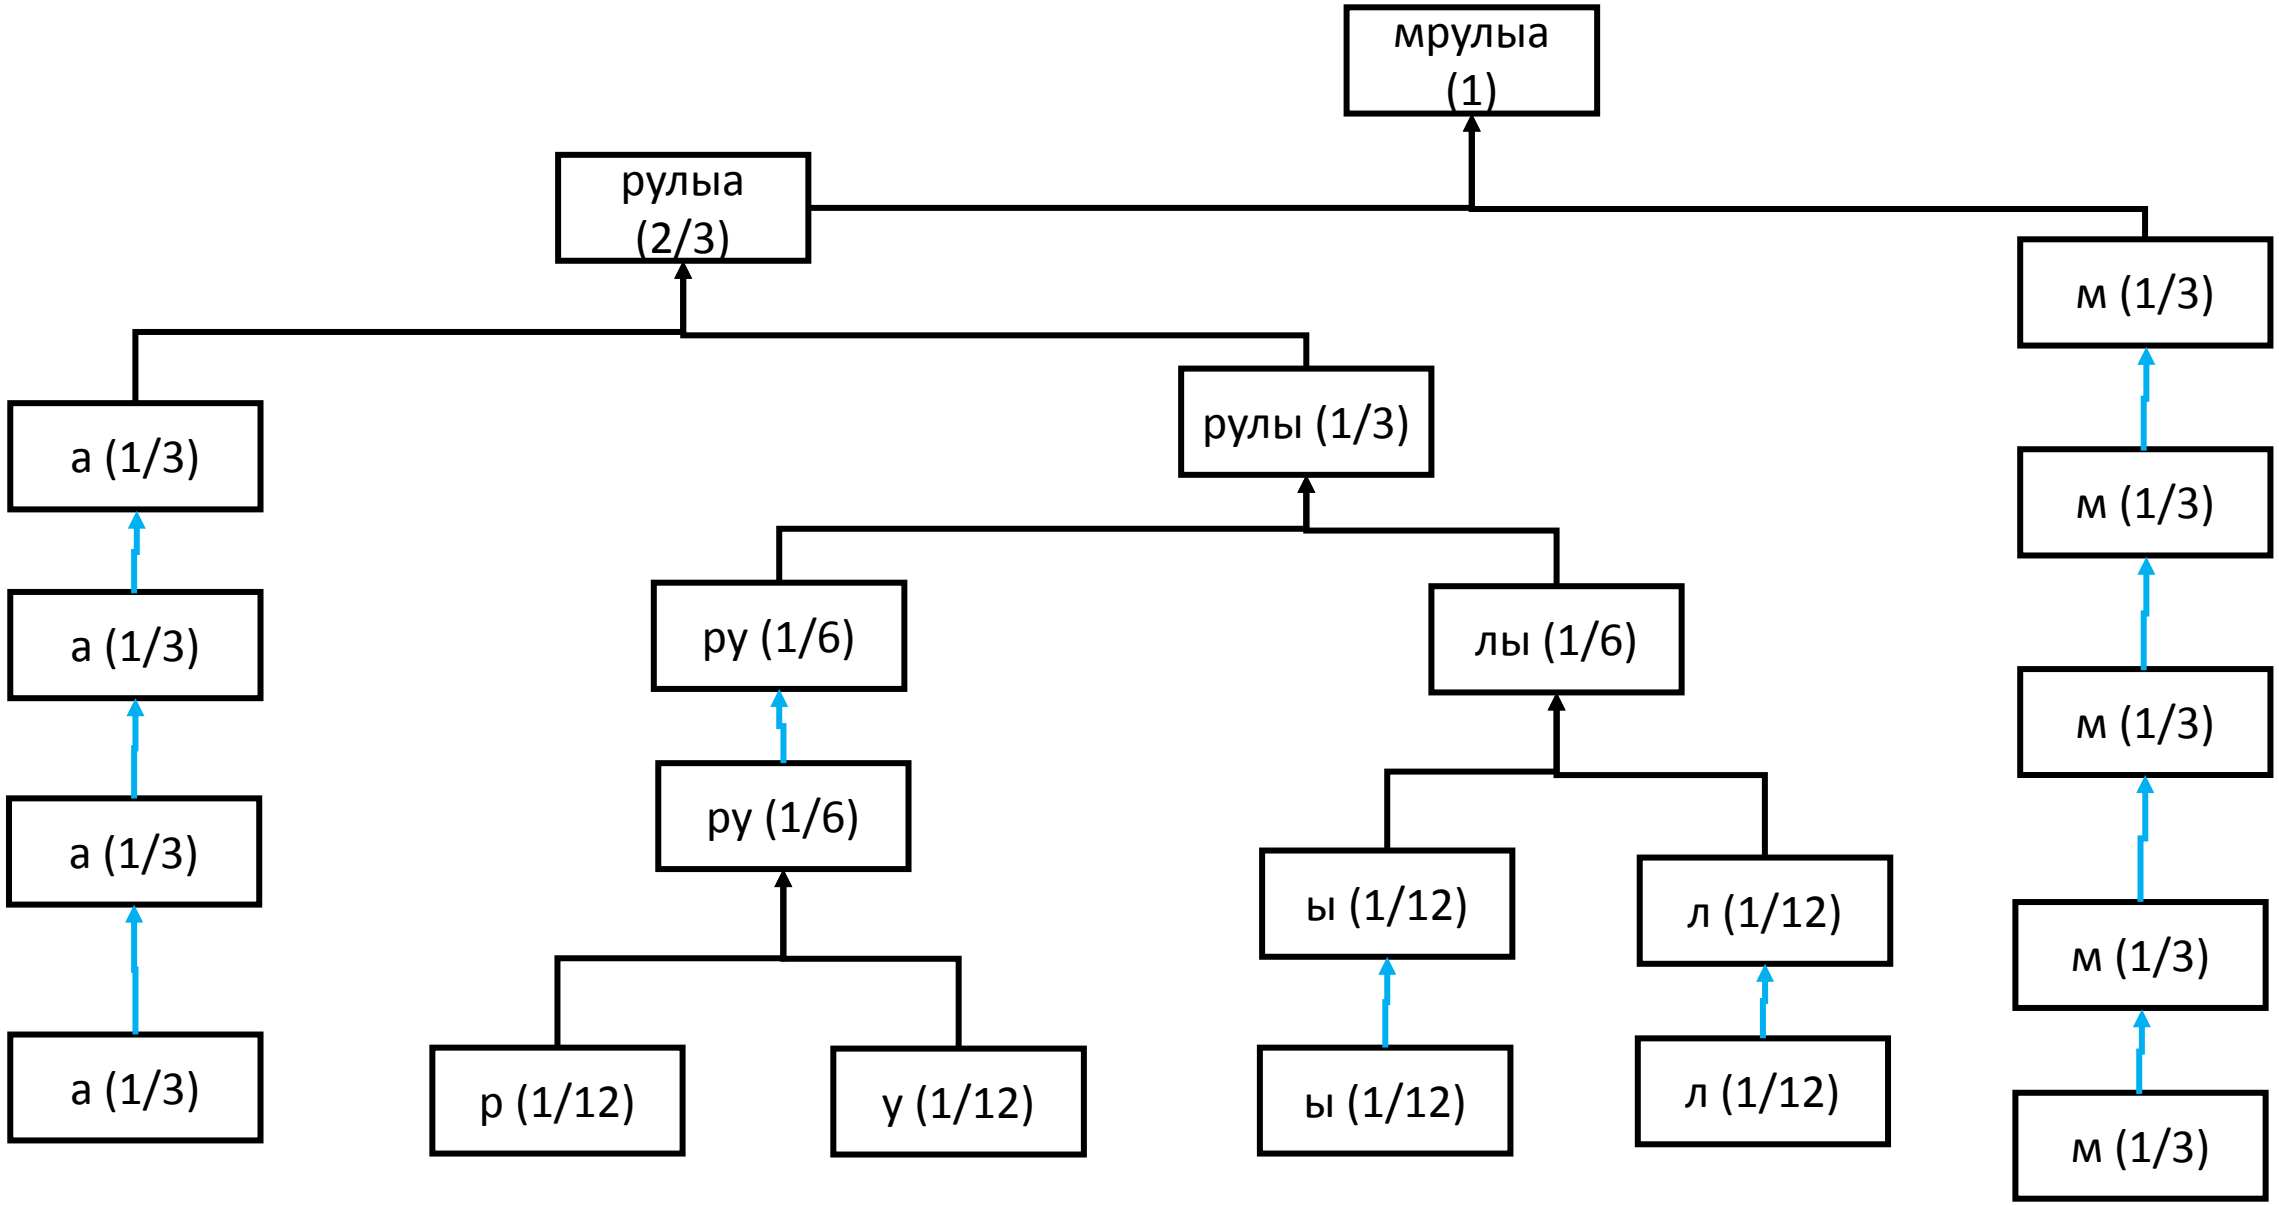

# Алгоритм Хаффмана

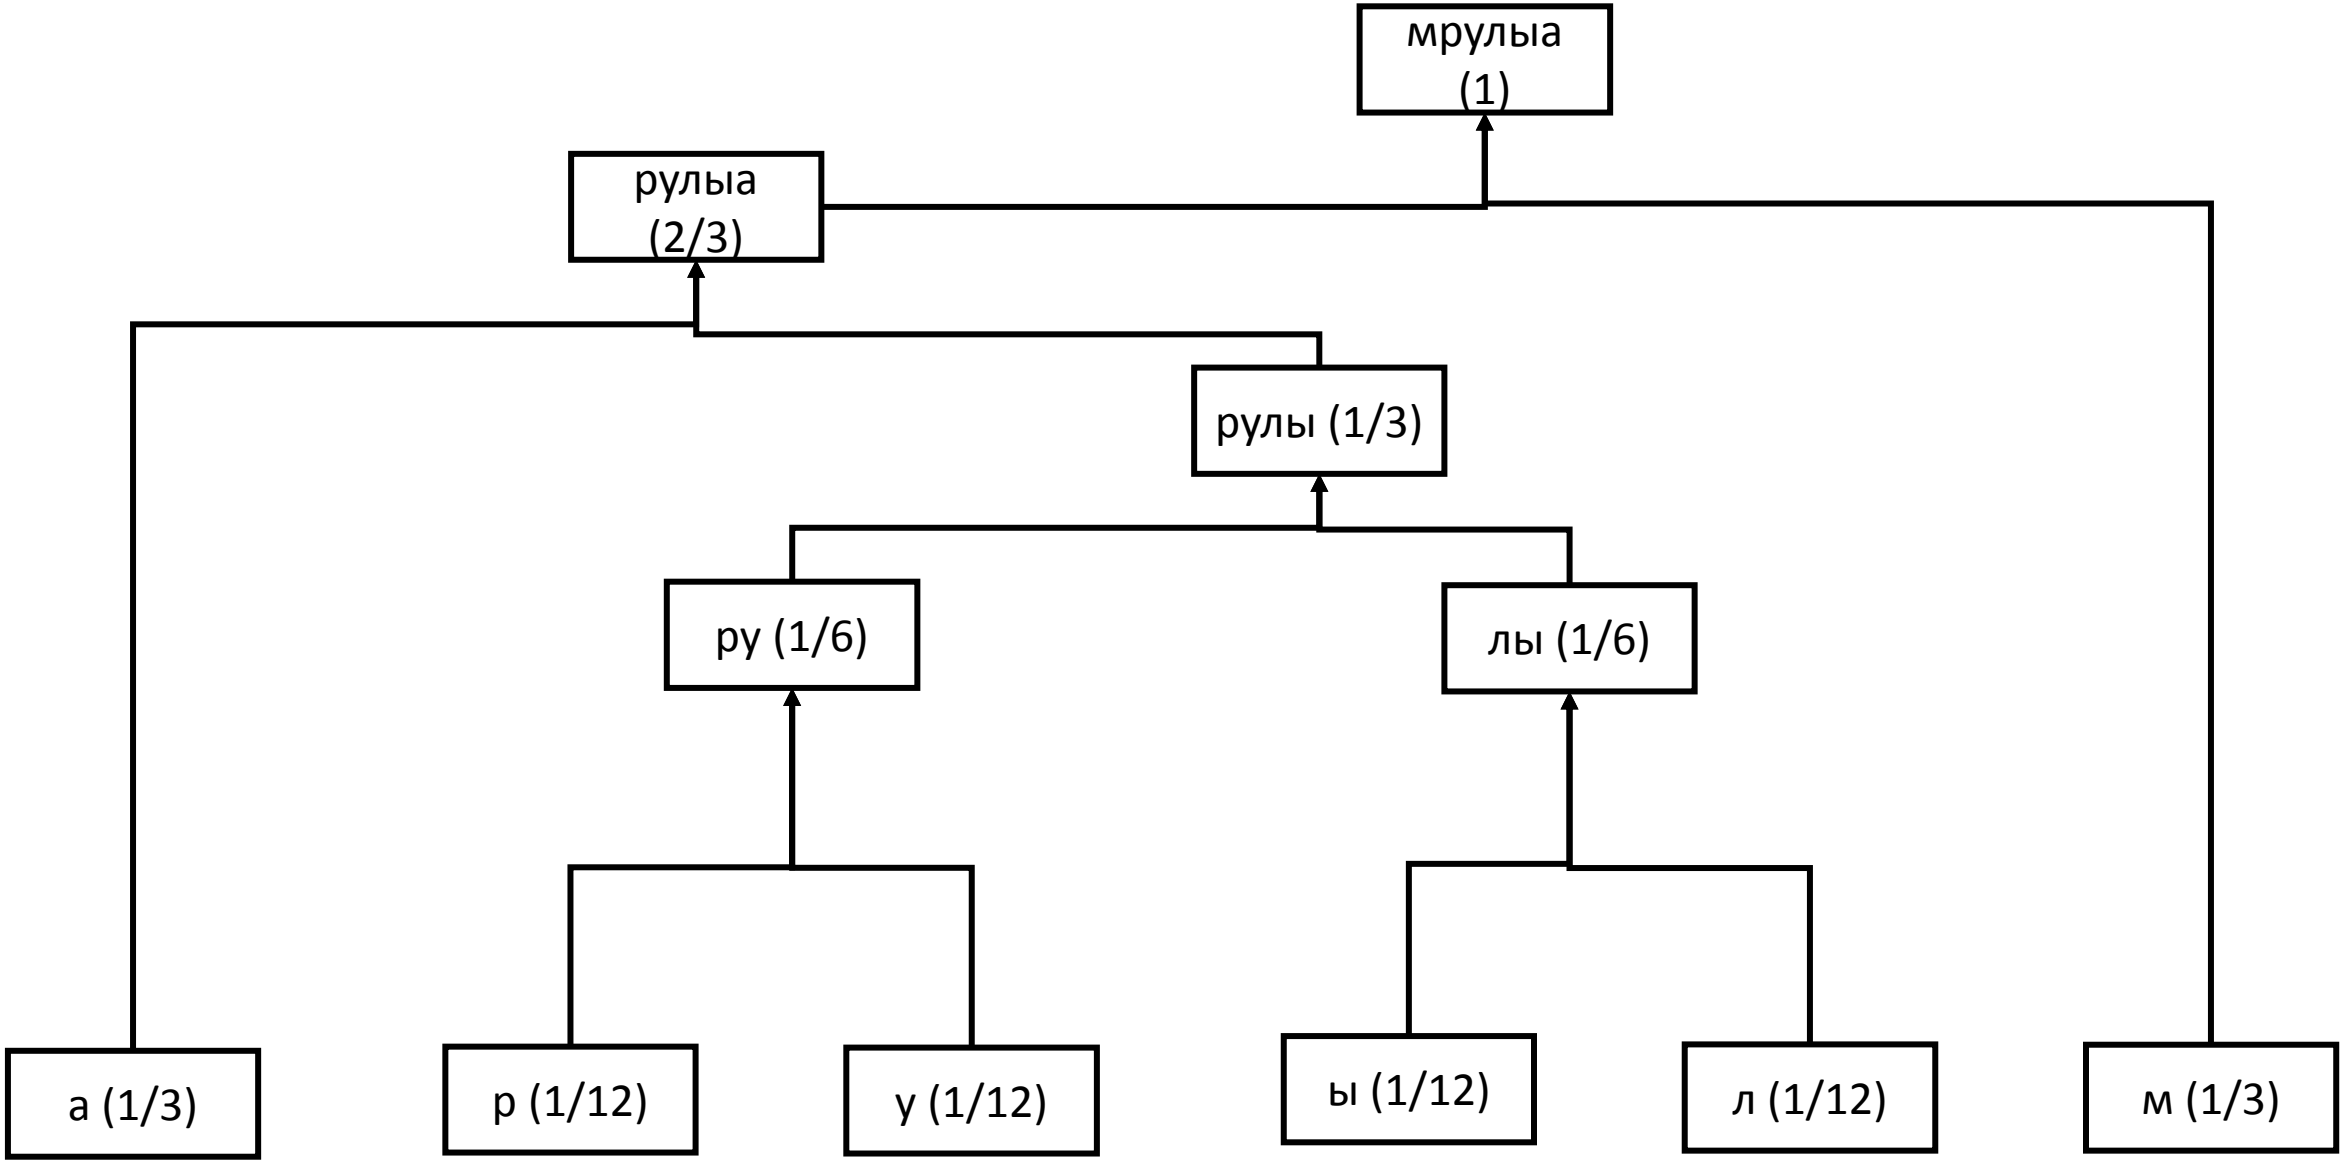

# Алгоритм Хаффмана

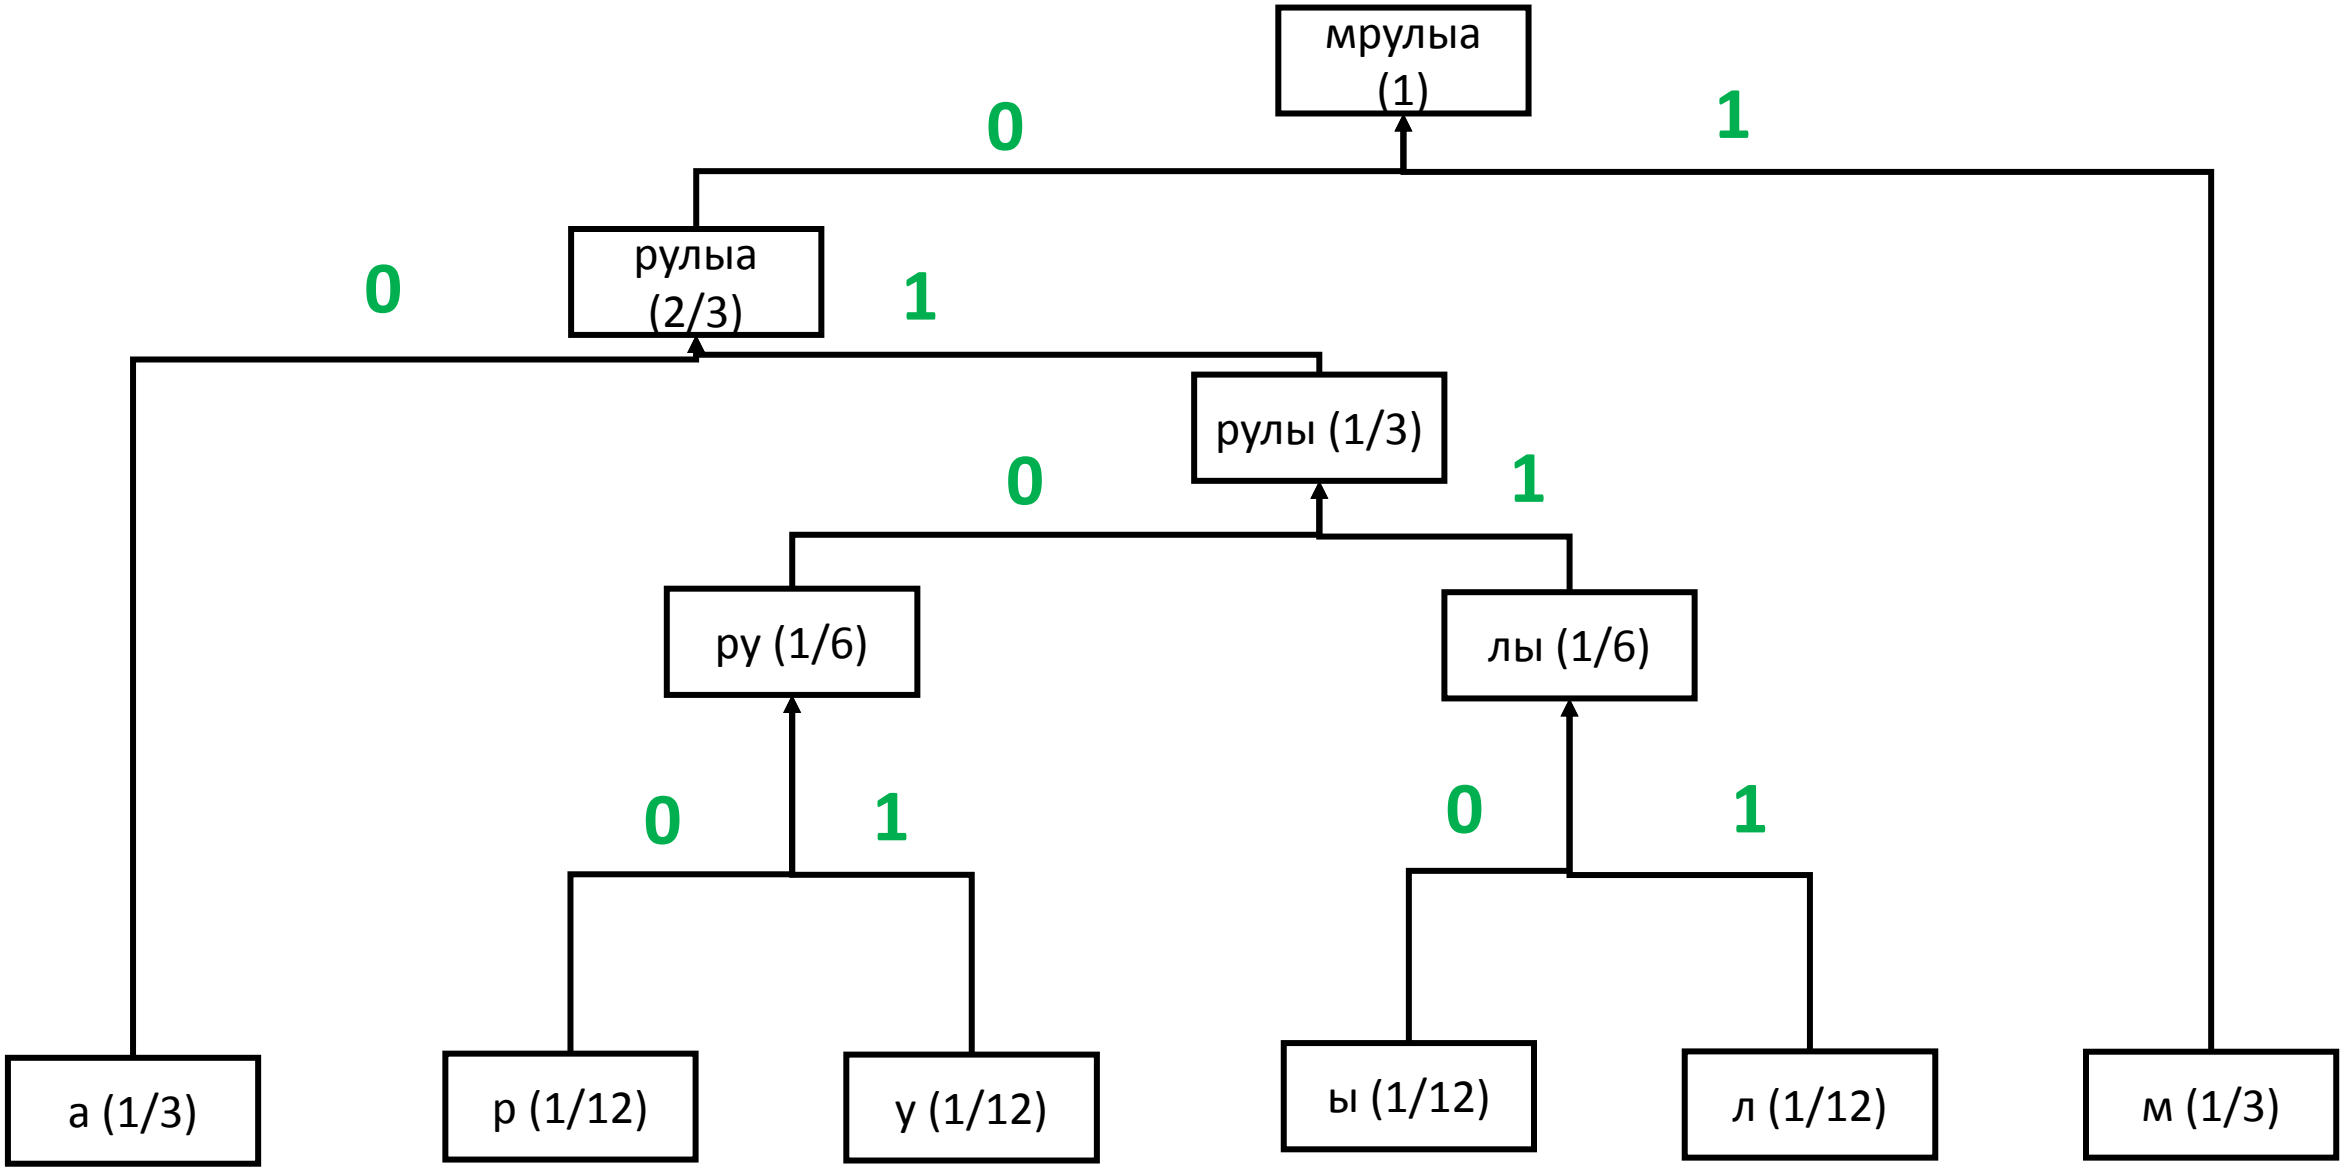

# Алгоритм Хаффмана

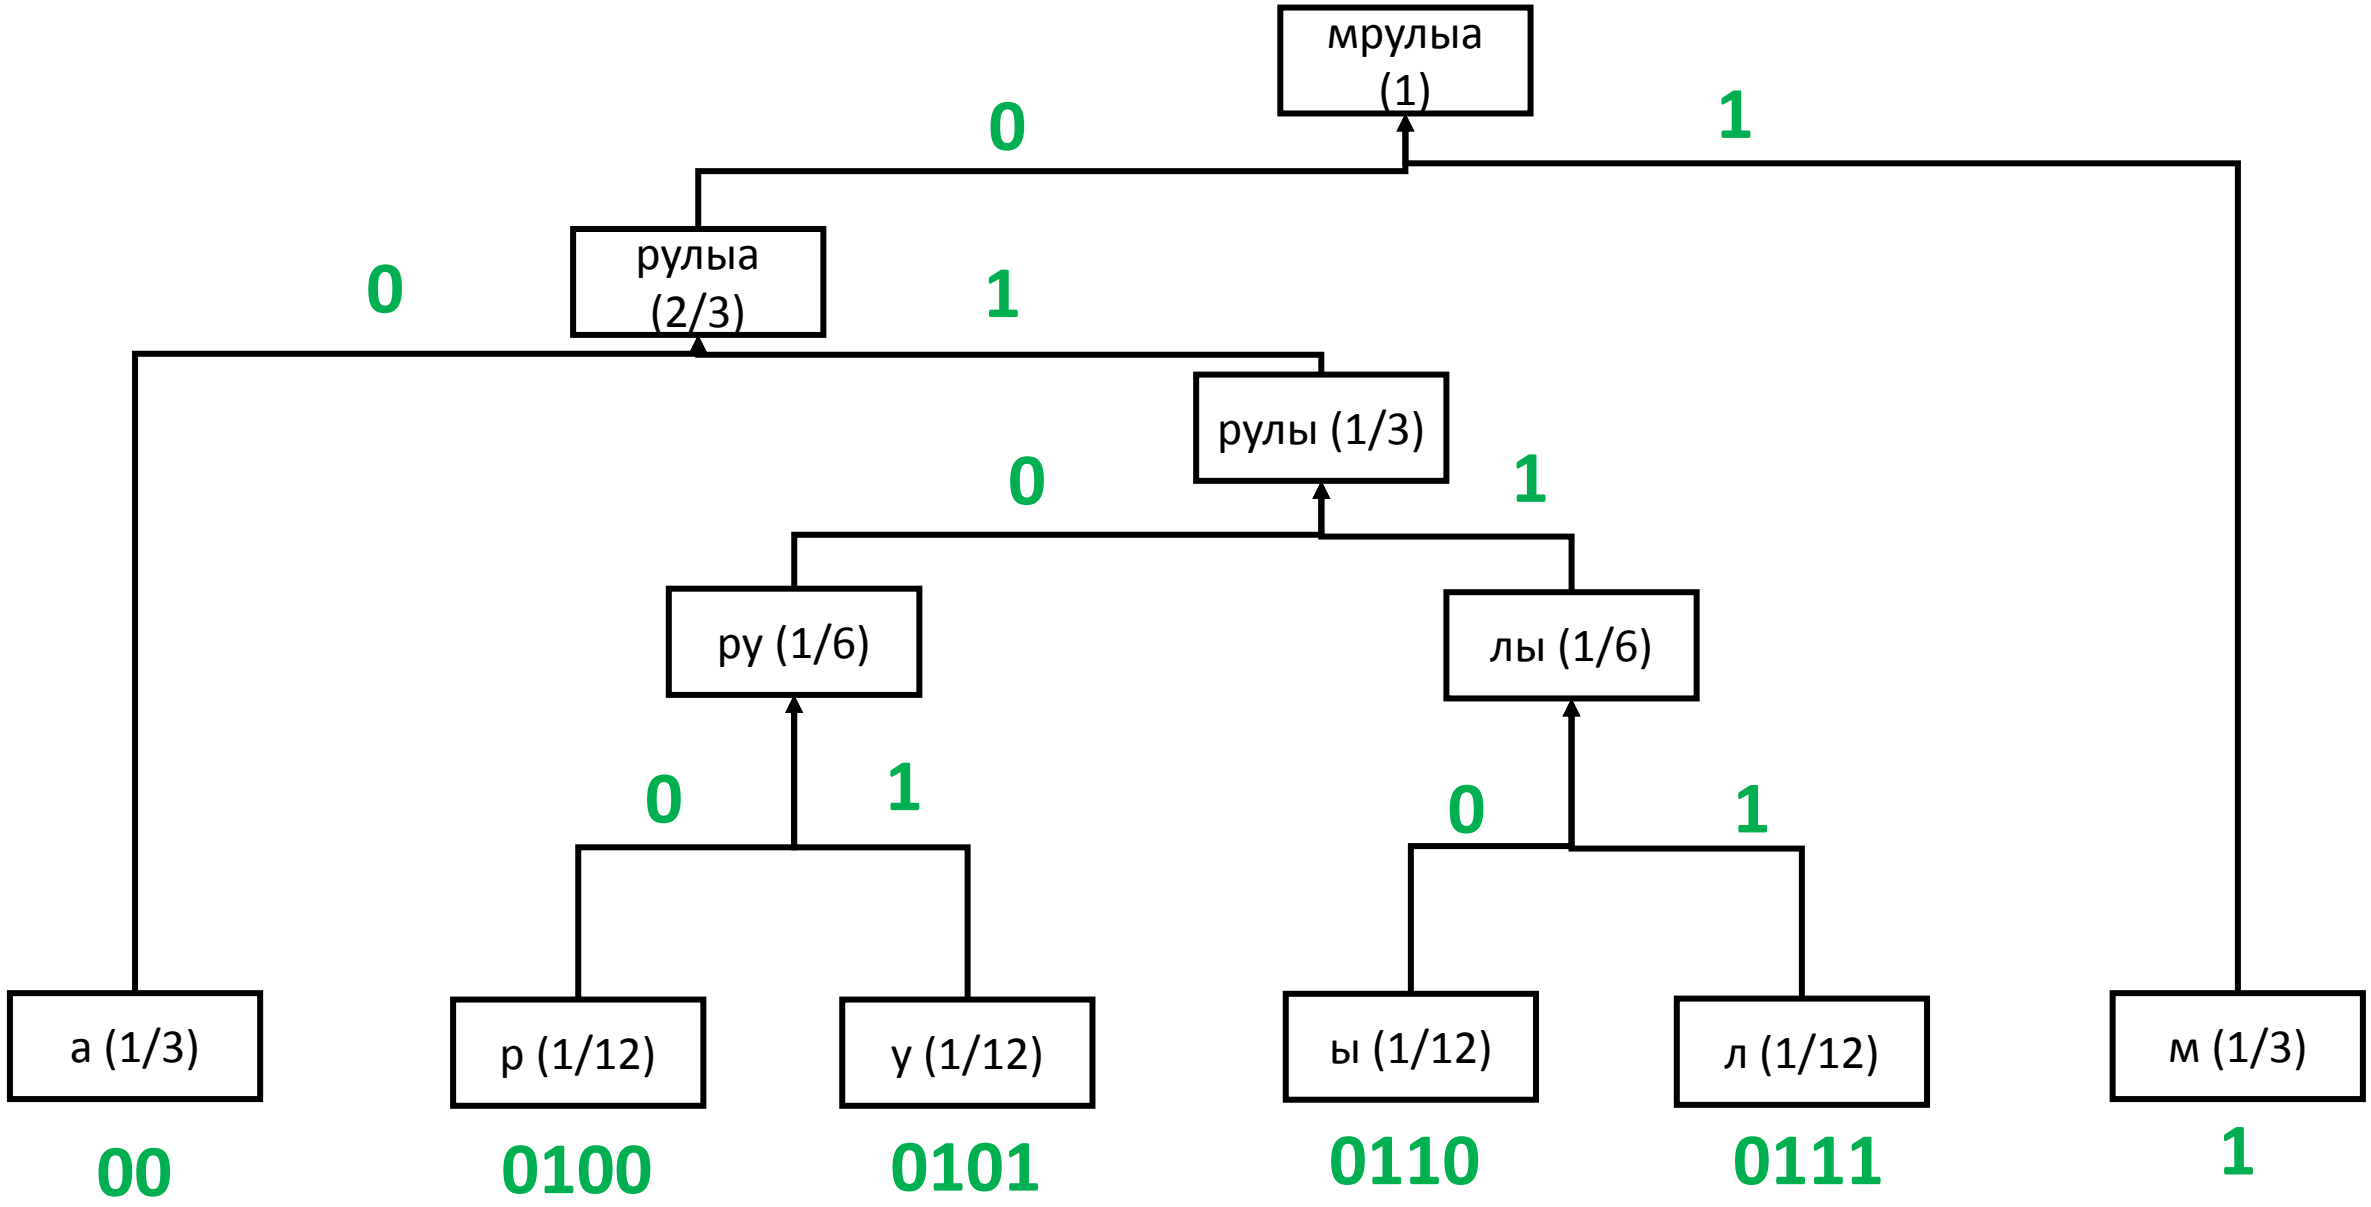

# Расчет битовых затрат

| | |
|---|---|
| Без кодирования | R = 8 |
| Кодирование «в лоб» | R ~ 2,42 |
| Метод Хаффмана | R ~ 2,33 |
| *Энтропия* | H ~ 2,25 |

# Возможная программная реализация

Программа может быть разделена на 6 модулей (см. следующий слайд). Порядок работы:

1) Открытие и чтение файла
2) Расчёт частоты встречаемости символов
3) Сортировка массива символов по частоте по убыванию
4) Создание дерева Хаффмана
5) Создание кодов Хаффмана
6) Создание промежуточного файла, состоящего из 0 и 1 – закодированный полученным кодом первый файл
7) Запись полученной последовательности в архивный файл

# Программная реализация

| math_func.c | types.h | arch_logic.c | information.c | file_In_out.c |
|---|---|---|---|---|
| Описание **математических функций** (расчет энтропии, битовых затрат и т.п.) | Описание **глобальных** типов | Описание **логики работы** архиватора | Вывод информации о работе программы | Работа со вводом и выводом |

| main.c |
|---|
| |

# Комментарии

Программа может быть реализована по следующим пунктам:

1) Открытие файла в бинарном виде и посимвольное чтение потока байтов
2) Расчет гистограммы появлений символов
3) Функция расчета энтропии по полученной в п. 2 гистограмме
4) Функция построения дерева Хаффмана
5) Функция создания кодов по полученному дереву
6) Кодирование входного файла с помощью полученных кодов и запись результата в текстовый файл. Данный файл представляет собой набор 0 и 1.
7) Создание нового файла, содержащий сжатый файл на основе полученного результата. *(см слайд 20)*

# Комментарии по реализации

**Равномерный код**

**мамамылараму** →

11101100111000001110110011100000111011001111101111101011111000001111000011100000111011001111001111

| Символ | Код (ASCII Win-1251) |
|---|---|
| м | 11101100 |
| а | 11100000 |
| ы | 11111011 |
| л | 11101011 |
| р | 11110000 |
| у | 11110011 |

# Комментарии по реализации

**Код Хаффмана**

**мамамылараму** → 1001001011001110001000010101

| Символ | Код Хаффмана |
|---|---|
| м | 1 |
| а | 00 |
| ы | 0110 |
| л | 0111 |
| р | 0100 |
| у | 0101 |

# Комментарии по реализации

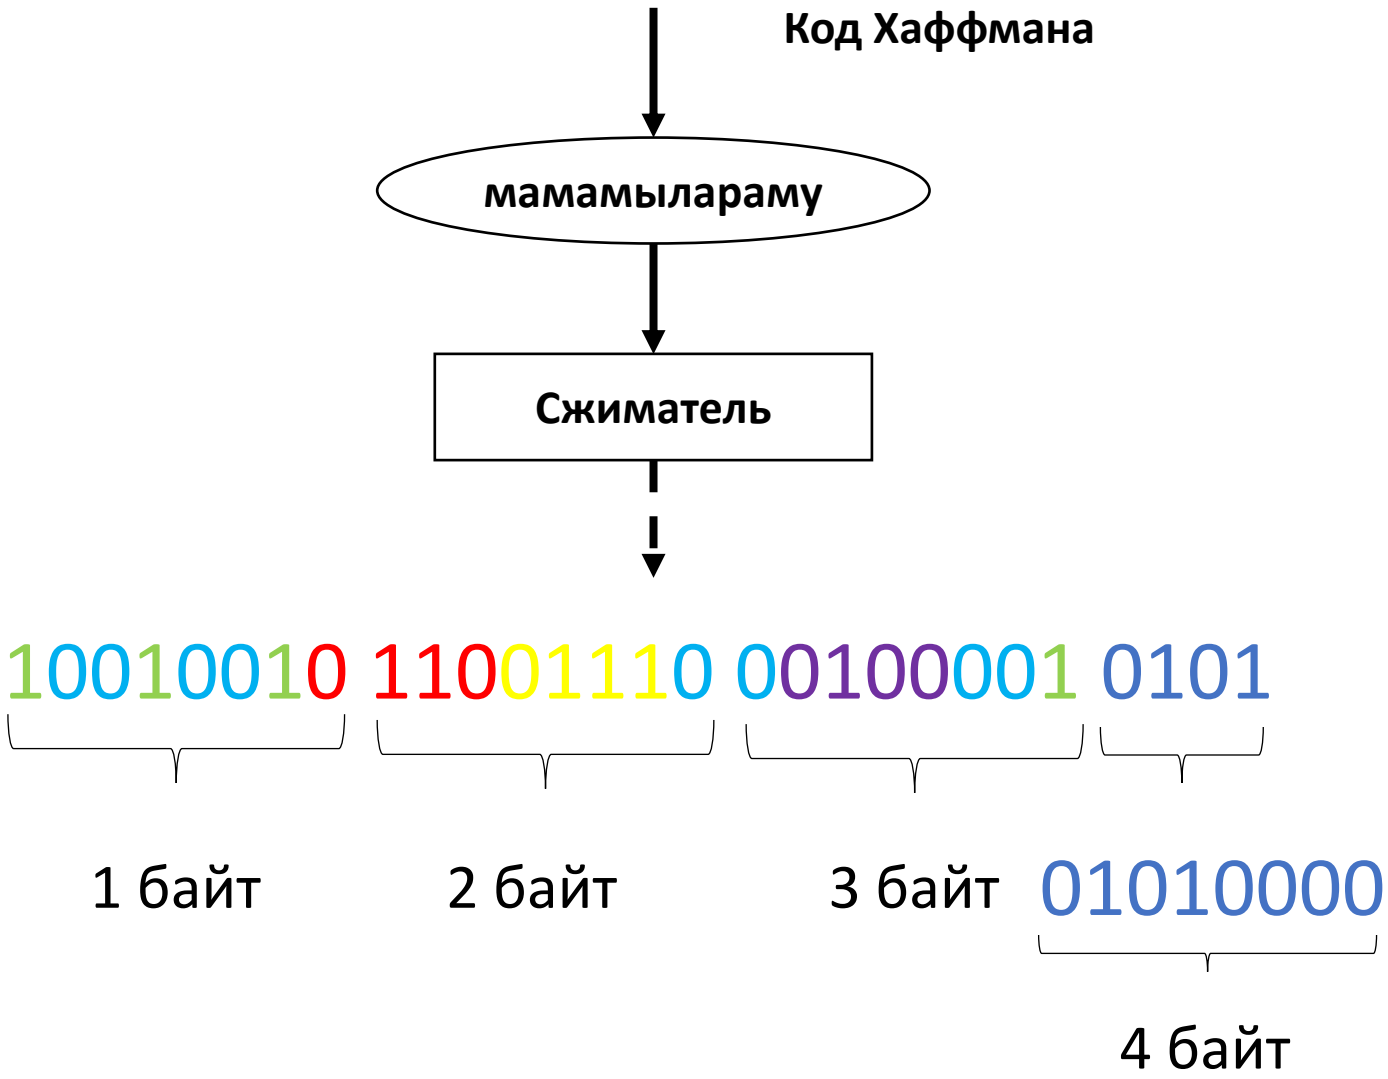


Дополняем нулями до 8 символов

# Комментарии по реализации

**Равномерный код**

**мамамылараму** → 111011001110000011101100 111000001110110011111011 111010111110000011110000 111000001110110011110011 → **12 байт**

**Код Хаффмана**

**мамамылараму** → 100100101100111000100001 0101 → **4 байта**

# Комментарии по реализации

Алгоритм построения дерева можно реализовать следующим образом:

1. Создание **рекурсивной функции** построения дерева Хафмана.

   *symbol* makeTree(symbol* psym[], int k)*

Передаем по указателю значение нового пришедшего элемента. В данном случае, самого нижнего. Также передаем общее количество символов k. Возвращаем - указатель на новую структуру типа symbol

2. Создание временной структуры symbol. В нее мы запишем новый символ, состоящий из суммы двух нижних

```
symbol* temp;
///
//т.к. символ состоит из последних двух, то запишем их как «родительские»
temp->left = psym[k - 2];
temp->right = psym[k - 1];
///
```

3. Заменяем эти два символа на получившийся новый и упорядочиваем дерево
4. Рекурсивно вызываем функцию makeTree, только с меньшим числом символов на 1, т.к. два из них склеились

```
return makeTree(psym, k - 1);
```

# Комментарии по реализации

Алгоритм построения кодов можно реализовать следующим образом:

1. Рекурсивная функция кодирования. На вход принимает указатель на полученный корень дерева

   *void makeCodes(symbol* root)*

2. Обходим дерево начиная с корня. Сначала идем налево. Если есть такой символ, то к уже полученному коду добавляем символ 0
3. Далее рекурсивно вызываем функцию, но уже для элемента, лежащего слева от него

Таким образом мы дойдем до конца дерева по левым ветвям. Далее аналогично добавляем возможность перебирать правые ветви.

# Комментарии по реализации

Для записи сжатого файла возможно использовать объединение и битовые поля:

```
union code {
    unsigned char sym_to_write;//переменная содержащая код для записи в сжатый файл

    struct byte //представлена в виде битового поля - каждый unsigned символ занимает 1 бит
    {
        unsigned b1 : 1;
        unsigned b2 : 1;
        unsigned b3 : 1;
        unsigned b4 : 1;
        unsigned b5 : 1;
        unsigned b6 : 1;
        unsigned b7 : 1;
        unsigned b8 : 1;
    }byte;
};
```

# Комментарии по реализации

Для записи сжатого файла возможно использовать объединение и битовые поля:

10010010

```
///
union code code1;//инициализируем переменную code1
code1.byte.b1 = 1;
code1.byte.b2 = 0;
code1.byte.b3 = 0;
code1.byte.b4 = 1;
code1.byte.b5 = 0;
code1.byte.b6 = 0;
code1.byte.b7 = 1;
code1.byte.b8 = 0;
///
```

code1. sym_to_write – содержит полученный символ, который записывается в файл

# Возможная программная реализация

Порядок работы:

А

1) Открытие и чтение файла
2) Расчёт частоты встречаемости символов
3) Сортировка массива символов по частоте по убыванию

Б

4) Создание дерева Хаффмана
5) Создание кодов Хаффмана
6) Создание промежуточного файла, состоящего из 0 и 1 – закодированный полученным кодом первый файл

В

7) Запись полученной последовательности в архивный файл

# Что рекомендуется сделать:

Т.к. не во всех группах мы успели пройти все необходимые вещи, то рекомендую придерживаться следующей таблички.
Безусловно, будет здорово, если вы пойдете вперед и решите все раньше остальных!

| После какого занятия нужно начинать делать | Часть |
|---|---|
| 3 | А |
| 4 | Б |
| 5 | В |

Желаю успеха!